# Kiến Trúc Giải Mã Tài Liệu Đa Phương Thức: Kết Hợp Neo Bố Cục Tường Minh Của Paddle, Luồng Nhân Quả Thị Giác DeepSeek Và Kết Nối Tắt Không Gian Kiểu U-Net

## Đánh Giá Tổng Quan Ý Tưởng Cốt Lõi Và Phản Biện Các Đề Xuất Kỹ Thuật Trước Đó

Trong lĩnh vực trí tuệ nhân tạo xử lý tài liệu (Document AI) tính đến cuối năm 2026, việc kết hợp khả năng định vị hình học tường minh của hệ sinh thái PaddleOCR với cơ chế suy luận nhân quả thị giác (visual causal flow) của DeepSeek-OCR 2, đồng thời bổ sung cơ chế truyền dẫn đặc trưng không gian ngược từ tầng mã hóa sang tầng giải mã tương tự kiến trúc U-Net, là một hướng tiếp cận có giá trị khoa học và thực tiễn rất cao. Tuy nhiên, khi đặt trong ràng buộc kỹ thuật của giai đoạn hiện tại là lắp ráp các mô hình có sẵn (zero-training modular assembly) mà không huấn luyện lại, việc phân biệt rõ ràng giữa tích hợp ở không gian đầu vào/đầu ra (input/output-space orchestration) và trộn lẫn ở không gian tiềm ẩn (latent-space fusion) đóng vai trò quyết định đến sự thành bại của toàn bộ hệ thống.
Một số đề xuất kiến trúc trước đó, chẳng hạn như việc dùng phép chiếu đa tầng \mathrm{MLP} ghép nối vector thị giác và tọa độ bounding box để thay thế trực tiếp chuỗi truy vấn của DeepSeek, hay gán ghép cơ chế phân nhánh của PaDoc thành kết nối tắt U-Net, tuy nắm bắt đúng trực giác ở mức vĩ mô nhưng lại chứa đựng những điểm nghẽn nghiêm trọng về mặt toán học biểu diễn khi triển khai không huấn luyện. Bảng dưới đây tổng hợp đánh giá kỹ thuật chi tiết đối với từng thành phần trong đề xuất trước đó và định hướng hiệu chỉnh chuẩn xác cho hệ thống.

| Thành phần đề xuất trước đó | Đánh giá tính khả thi kỹ thuật | Nguyên nhân cốt lõi / Bản chất kiến trúc thực tế | Giải pháp hiệu chỉnh (Giai đoạn lắp ráp & Giai đoạn Adapter) |
|---|---|---|---|
| Thay thế LayoutLMv3 + Reading Order Encoder bằng **PP-DocLayoutV3** | **Đồng thuận hoàn toàn (Tối ưu)** | LayoutLMv3 cần văn bản/OCR có sẵn; PP-DocLayoutV3 (33M tham số) dự đoán đồng thời bbox, đa giác, mặt nạ và thứ tự đọc trong 1 lượt chạy ở tốc độ 132,1 FPS. | Sử dụng trực tiếp PaddlePaddle/PP-DocLayoutV3 làm tầng tiền xử lý hình học duy nhất. |
| Tạo truy vấn q_k = \mathrm{MLP}(v_k \oplus b_k) thay thế trực tiếp causal queries | **Bất khả thi khi không huấn luyện** | Causal-flow queries của DeepEncoder V2 là giao diện tính toán đã học (learned interface) | **Giai đoạn lắp ráp:** Điều kiện hóa ở mức ảnh cắt (crop) + định tuyến prompt. **Giai** |

| Thành phần đề xuất trước đó | Đánh giá tính khả thi kỹ thuật | Nguyên nhân cốt lõi / Bản chất kiến trúc thực tế | Giải pháp hiệu chỉnh (Giai đoạn lắp ráp & Giai đoạn Adapter) |
|---|---|---|---|
| của DeepSeek-OCR 2 | | với mặt nạ chú ý riêng; vector ngoại lai gây lệch phân phối (manifold mismatch). | **đoạn nâng cao:** Giữ nguyên Q_0, dùng Cross-Attention có cổng (gated residual). |
| Đồng nhất cơ chế của **PaDoc** với kết nối tắt (skip connection) kiểu U-Net | **Sai lệch về bản chất kiến trúc** | PaDoc là cơ chế phân nhánh giải mã theo đồ thị DAG (ancestor attention + fork tokens) để tăng tốc độ sinh song song, không phải truyền tắt đặc trưng không gian đa tầng. | Tham chiếu kiến trúc **SARA** (*Spatial Alignment Residual Adapter*, \hat{T} = T + \lambda G') cho kết nối tắt U-Net thực thụ từ các tầng thị giác sớm. |
| Cộng trực tiếp vector tọa độ bounding box vào mọi bước sinh token ở Decoder | **Rủi ro nhiễu loạn biểu diễn** | Không có bằng chứng PaDoc cộng thẳng vector tọa độ vào mọi token; phép cộng tùy tiện vào không gian ẩn của LLM chưa qua huấn luyện sẽ phá vỡ phân phối từ vựng. | Dùng định tuyến prompt ở giai đoạn lắp ráp; dùng token tiền tố (prefix tokens) hoặc Gated Cross-Attention khi huấn luyện adapter. |
| Duy trì **Global Context Queries** để cứu các vùng bị bộ phát hiện bố cục bỏ sót | **Đồng thuận cao (Rất quan trọng)** | Mọi hệ thống hai giai đoạn đều chịu rủi ro lỗi lan truyền nếu bộ phát hiện bố cục bỏ sót văn bản nhỏ, chú thích cuối trang hoặc công thức rời rạc. | **Giai đoạn lắp ráp:** Chạy song song 1 lượt DeepSeek-OCR 2 toàn trang + bộ dò văn bản dư (residual text detector). **Khi huấn luyện:** Giữ nhóm truy vấn không neo (unanchored queries). |
| Khai thác học kết hợp (coupled reading-order) giảm lỗi từ 0,189 \rightarrow 0,041 | **Chính xác về mặt số liệu** | Nghiên cứu RT-DocLayout chứng minh việc học chung bố cục và thứ tự đọc giúp giảm khoảng 78,3% sai số khoảng cách chỉnh sửa tương đối so với kiến trúc tách rời. | Loại bỏ hoàn toàn ý tưởng xây dựng một bộ mã hóa thứ tự đọc (Reading Order Encoder) độc lập phía sau bộ phát hiện bounding box. |
| Dùng *Under-Optimized Region Refinement* của PaddleOCR-VL-1.6 để tinh chỉnh \Delta x, \Delta y, \Delta w, \Delta h lúc suy luận | **Hiểu sai bản chất công trình** | Trong PaddleOCR-VL-1.6, đây là khung tối ưu hóa dữ liệu ngoại tuyến (khai phá vùng thưa dữ liệu + hậu huấn luyện RL), không phải đầu | Không tìm kiếm module hồi quy tọa độ trong checkpoint PaddleOCR-VL-1.6; thay bằng cơ chế đối chiếu nhãn ngữ nghĩa giữa Layout và VLM. |

| Thành phần đề xuất trước đó | Đánh giá tính khả thi kỹ thuật | Nguyên nhân cốt lõi / Bản chất kiến trúc thực tế | Giải pháp hiệu chỉnh (Giai đoạn lắp ráp & Giai đoạn Adapter) |
|---|---|---|---|
| | | hồi quy tọa độ lúc suy luận. | |
| Áp dụng **ParseFixer** với cơ chế kiểm chứng - quay lui (verify-and-rollback) và tăng nhiệt độ 0,1 \rightarrow 0,8 | **Đồng thuận cơ chế, bác bỏ chi tiết nhiệt độ** | ParseFixer sử dụng FBP (toàn trang) kết hợp ASC (sửa lỗi chọn lọc có kiểm chứng), nhưng bài báo gốc không chứng minh quy tắc tự động tăng nhiệt độ từ 0,1 lên 0,8. | Triển khai bộ kiểm tra cú pháp tiền định (LaTeX, HTML, Markdown) để kích hoạt nhận dạng lại cục bộ; giữ nhiệt độ của DeepSeek-OCR 2 ở mức khuyến nghị (0,0) hoặc thử nghiệm như một siêu tham số riêng. |

# Giải Phẫu Bốn Điểm Nghẽn Kiến Trúc Trong Thiết Kế Ban Đầu

## 1. Lý do loại bỏ LayoutLMv3 và bộ mã hóa thứ tự đọc rời rạc

Trong phác thảo ban đầu, luồng xử lý dự kiến sử dụng LayoutLMv3 để chuyển đổi ảnh tài liệu thành các bounding box, sau đó đưa các hộp giới hạn này qua một bộ mã hóa thứ hai để tìm thứ tự đọc. Tuy nhiên, xét về mặt cấu trúc đầu vào, LayoutLMv3 không phải là một bộ phát hiện đối tượng thị giác độc lập (visual object detector); mô hình này yêu cầu đầu vào bao gồm ảnh tài liệu đi kèm với các từ và tọa độ vị trí đã được trích xuất sẵn từ một hệ thống OCR bên ngoài để học biểu diễn đa phương thức chung. Việc dùng LayoutLMv3 để sinh bounding box từ ảnh thô là không tương thích về mặt chức năng.
Thay vào đó, công trình **RT-DocLayout** (được phát hành mã nguồn mở dưới tên **PP-DocLayoutV3** trong hệ sinh thái PaddleOCR) giải quyết trọn vẹn bài toán này bằng một kiến trúc thống nhất chỉ 33 triệu tham số dựa trên nền tảng RT-DETR. Trong một lượt truyền xuôi (forward pass) duy nhất với tốc độ lên tới 132,1 FPS, PP-DocLayoutV3 thực hiện đồng thời bốn tác vụ: phân loại nhãn ngữ nghĩa (C_k), phát hiện hộp giới hạn hoặc đa giác nhiều điểm (B_k), phân đoạn mặt nạ mức điểm ảnh (M_k) cho các tài liệu bị cong vênh hoặc biến dạng phối cảnh, và dự đoán trực tiếp thứ tự đọc logic (O_k). Đặc biệt, nghiên cứu RT-DocLayout chỉ ra rằng khi tách rời bộ dự đoán thứ tự đọc khỏi bộ phát hiện bố cục (decoupled setup), khoảng cách chỉnh sửa thứ tự đọc (Reading Order Edit Distance) ở mức cao là 0,189; ngược lại, khi tích hợp học chung (coupled learning) ngay trong một mô hình, sai số này giảm mạnh xuống chỉ còn 0,041, tương đương mức giảm 78,3% lỗi tương đối. Do đó, việc thay thế cụm "LayoutLMv3 + Reading Order Encoder" bằng PP-DocLayoutV3 vừa loại bỏ một bước trung gian dư thừa, vừa mang lại độ chính xác hình học vượt trội. Dữ liệu thực nghiệm dưới đây minh chứng rõ hiệu năng vượt trội của RT-DocLayout (PP-DocLayoutV3) so với các tầng phát hiện bố cục khác khi ghép nối với các bộ nhận dạng đa phương thức.

| Mô hình phân tích bố cục | Tham số | Tốc độ (FPS) | Phương pháp nhận dạng ghép nối | Điểm tổng thể (Overall \uparrow) | Sai số văn bản (Text Edit \downarrow) | Công thức (Formula CDM \uparrow) | Bảng biểu (Table TEDS \uparrow) | Sai số thứ tự đọc (RO Edit \downarrow) |
|---|---|---|---|---|---|---|---|---|
| **DocLayo** | 20M | 107,4 | PaddleOC | 87,29 | 0,127 | 88,74 | 85,83 | 0,169 |

| Mô hình phân tích bố cục | Tham số | Tốc độ (FPS) | Phương pháp nhận dạng ghép nối | Điểm tổng thể (Overall \uparrow) | Sai số văn bản (Text Edit \downarrow) | Công thức (Formula CDM \uparrow) | Bảng biểu (Table TEDS \uparrow) | Sai số thứ tự đọc (RO Edit \downarrow) |
|---|---|---|---|---|---|---|---|---|
| **ut-YOLO** | | | R-VL-1.5-0.9B | | | | | |
| **Dolphin-v2 (Layout)** | 3B | 0,9 | PaddleOCR-VL-1.5-0.9B | 90,36 | 0,049 | 87,60 | 88,36 | 0,060 |
| **MinerU2.5 (Layout)** | 1,2B | 2,4 | PaddleOCR-VL-1.5-0.9B | 91,31 | 0,046 | 87,57 | 90,92 | 0,051 |
| **PP-DocLayoutV2** | 53M | 110,9 | PaddleOCR-VL-1.5-0.9B | 93,56 | 0,034 | 92,09 | 92,03 | 0,042 |
| **RT-DocLayout (PP-DocLayoutV3)** | 33M | 132,1 | MonkeyOCR | 92,51 | 0,039 | 92,37 | 89,07 | 0,044 |
| **RT-DocLayout (PP-DocLayoutV3)** | 33M | 132,1 | MinerU2.5 | 92,68 | 0,043 | 92,19 | 90,12 | 0,049 |
| **RT-DocLayout (PP-DocLayoutV3)** | 33M | 132,1 | Dolphin-v2 | 90,72 | 0,060 | 89,17 | 89,00 | 0,058 |
| **RT-DocLayout (PP-DocLayoutV3)** | 33M | 132,1 | PaddleOCR-VL-1.5-0.9B | 94,50 | 0,035 | 94,21 | 92,76 | 0,042 |
| **PP-DocLayoutV3 (Chuẩn v1.6)** | 33M | 132,1 | PaddleOCR-VL-1.6-0.9B | 96,33 | — | — | — | — |

## 2. Sự bất tương thích của phép ghép nối truy vấn không huấn luyện vào DeepSeek-OCR 2

Ý tưởng trích xuất vector đặc trưng vùng ảnh $v_k = \operatorname{RoIAlign}(V, B_k)$ kết hợp với vector hình học $b_k = f_{\text{geometry}}(B_k)$ thông qua mạng $\mathrm{MLP}$ để tạo thành truy vấn $q_k = \mathrm{MLP}([v_k; b_k])$ rồi đưa thẳng vào bộ giải mã của DeepSeek-OCR 2 sẽ gặp phải rào cản lớn nếu không thực hiện huấn luyện. Nguyên nhân bắt nguồn từ kiến trúc đặc thù của **DeepEncoder V2** bên trong mô hình 3 tỷ tham số DeepSeek-OCR 2 (công bố tháng 1/2026).

Khác với các mô hình ngôn ngữ thị giác (VLM) truyền thống vốn chỉ dùng bộ mã hóa kiểu CLIP để quét ảnh theo thứ tự lưới cố định (raster-scan từ trái sang phải, từ trên xuống dưới),

DeepSeek-OCR 2 thiết kế chuỗi đầu vào của bộ mã hóa dưới dạng ghép nối [\text{visual tokens}; \text{causal-flow queries}]. Trong đó, phần bộ phân tách thị giác (vision tokenizer) kết hợp mô hình SAM (Segment Anything Model) và các tầng tích chập để nén ảnh xuống 16\times, tạo ra các token thị giác sử dụng cơ chế chú ý hai chiều (bidirectional attention) nhằm nắm bắt ngữ cảnh toàn cục. Ngược lại, phần thứ hai của bộ mã hóa thay thế kiến trúc tĩnh bằng một mô hình ngôn ngữ nhỏ (khởi tạo từ Qwen2-0.5B) vận hành trên các **truy vấn luồng nhân quả học sẵn (learnable causal-flow queries)**. Các truy vấn này áp dụng mặt nạ chú ý một chiều (causal attention mask): mỗi truy vấn có thể quan sát toàn bộ token thị giác và các truy vấn đứng trước nó, nhưng không được nhìn thấy các truy vấn tương lai, qua đó buộc bộ mã hóa phải tự suy luận và sắp xếp lại thông tin thị giác theo trình tự đọc tự nhiên trước khi chuyển giao phần đầu ra của chuỗi truy vấn này cho bộ giải mã LLM.
Do số lượng truy vấn luồng nhân quả được thiết kế bằng đúng số lượng token thị giác theo công thức (W \times H) / (16 \times 16) — cụ thể gồm 256 truy vấn toàn cục (\text{query}_{\text{global}}) ở độ phân giải 1024 \times 1024 cộng với k \times 144[span_14](start_span)[span_14](end_span)[span_17](start_span)[span_17](end_span) truy vấn cục bộ (\text{query}_{\text{local}}) từ k \in \{0, \dots, 6\} vùng cắt ở độ phân giải 768 \times 768, tạo ra tổng cộng từ 256 đến 1120 token đầu vào cho LLM — việc thay thế trực tiếp các truy vấn này bằng vector q_k tự tạo dẫn đến ba sự lệch pha nghiêm trọng. Trước hết là hiện tượng lệch phân phối đa tạp (distribution/manifold mismatch), bởi bộ giải mã của DeepSeek-OCR 2 được tối ưu hóa đồng thời (co-optimized) với đầu ra của chuỗi causal-flow queries. Một vector sinh ra từ bộ mã hóa ngoại lai hoặc từ một tầng \mathrm{MLP} khởi tạo ngẫu nhiên hoàn toàn nằm ngoài không gian biểu diễn tiềm ẩn (latent manifold) mà bộ giải mã hiểu được, dẫn đến hiện tượng sinh văn bản vô nghĩa ngay lập tức nếu không huấn luyện. Ngay cả trong công trình **LayTextLLM** (*A Bounding Box is Worth One Token*), nơi mỗi tọa độ [x_1, y_1, x_2, y_2] được nén thành một token duy nhất qua bộ chiếu **Spatial Layout Projector (SLP)** theo công thức z = W_2 \cdot (\operatorname{GeLU}(W_1 \cdot c + b_1)) + b_2, nhóm tác giả vẫn bắt buộc phải huấn luyện SLP cùng mô-đun **P-LoRA** (x_b^{\text{out}} = W_0 x_b + W_B W_A x_b + B_0) qua giai đoạn tiền huấn luyện căn chỉnh bố cục - văn bản thì LLM mới hiểu được token tọa độ đó. Thứ hai là sự lệch lực lượng tập hợp (cardinality mismatch), khi DeepEncoder V2 vận hành ở mật độ từ 256 đến 1120 token truy vấn, trong khi một trang tài liệu qua PP-DocLayoutV3 thường chỉ chứa N \in [15, 50] vùng bố cục (bounding boxes). Thứ ba là điểm nghẽn cổ chai dung lượng ngữ nghĩa (semantic capacity bottleneck), bởi một hộp giới hạn bao quanh một bảng biểu tài chính phức tạp có thể chứa hàng trăm ô dữ liệu và hàng nghìn ký tự; nếu ép toàn bộ vùng này thành một vector truy vấn q_k duy nhất, thông tin chi tiết sẽ bị triệt tiêu hoàn toàn. Vì vậy, nguyên tắc cốt lõi cho kiến trúc đề xuất là tuyệt đối không thay thế chuỗi truy vấn luồng nhân quả của DeepSeek, mà chỉ sử dụng thông tin hình học từ Paddle để điều kiện hóa (condition) chúng — ở mức cắt ảnh vật lý trong giai đoạn không huấn luyện, và ở mức chú ý chéo có cổng (gated cross-attention) khi huấn luyện adapter.

## 3. Phân định ranh giới giữa phân nhánh DAG (PaDoc) và kết nối tắt không gian U-Net (SARA)

Mối liên hệ trực giác với kiến trúc **U-Net** trong đề xuất ban đầu — tức là truyền thẳng thông tin hình học và đặc trưng độ phân giải cao từ nhánh mã hóa sang nhánh giải mã để định vị và gán nhãn chính xác — là một tư duy rất sắc bén. Tuy nhiên, việc gán ghép công trình **PaDoc** (*Layout-Grounded Parallel Decoding for Document Parsing*, tháng 8/2026) làm đại diện cho kết nối tắt U-Net là chưa chuẩn xác về mặt cơ chế mạng nơ-ron.
Về bản chất, PaDoc mô hình hóa tiến trình giải mã tài liệu dưới dạng một đồ thị có hướng

không chu trình (DAG) thông qua mặt nạ chú ý tổ tiên (**ancestor-attention mask**) và cơ chế giải mã token phân nhánh (**fork-token decoding**). Thay vì bắt mô hình tự hồi quy tuần tự từ đầu đến cuối trang, PaDoc sử dụng một tiền tố chung toàn trang (shared full-page image/layout prefix) nằm trong bộ nhớ đệm KV-cache, sau đó tại mỗi nút bố cục sẽ phát sinh các nhánh nội dung vùng ($Y_k$) chạy song song độc lập với nhau. Cơ chế chú ý tổ tiên đảm bảo mỗi nhánh chỉ nhìn thấy tiền tố chung và các nút tổ tiên hợp lệ ($X, B_{\le k} \rightarrow Y_k$) mà không phụ thuộc vào nội dung của các nhánh anh em (sibling branches), giúp tăng thông lượng suy luận từ 67,4\% đến 118\% và giảm độ trễ P95 từ 39,2\% đến 54,9\% trên GPU A800. Như vậy, PaDoc giải quyết bài toán phân rã sự phụ thuộc tuần tự trong quá trình sinh token, chứ không thực hiện việc truyền tắt bản đồ đặc trưng thị giác từ tầng nông sang tầng sâu ($\text{encoder feature}_l \rightarrow \text{decoder feature}_{L-l}$) như U-Net.

Công trình thực sự hiện thực hóa đúng triết lý "U-Net trong VLM" vừa được công bố vào ngày 14/10/2026 là **Read, Parse, Describe** với mô-đun **SARA** (*Spatial Alignment Residual Adapter*). Nhóm tác giả của SARA nhận thấy rằng khi các VLM hiện đại nén và gộp các token thị giác (token merging/compression) để đưa vào bộ giải mã, các bằng chứng không gian cục bộ (local spatial evidence) và ranh giới sắc nét của đối tượng bị làm mờ đi nghiêm trọng, gây ra lỗi gán sai thuộc tính (attribute binding problem) giữa hộp giới hạn, nhãn phân loại và nội dung văn bản. Để khắc phục mà không cần tinh chỉnh lại toàn bộ mô hình nền (frozen backbone), SARA trích xuất các trạng thái ẩn trung gian (intermediate visual hidden states) từ nhiều tầng sớm và trung bình của bộ mã hóa thị giác (cụ thể là các tầng $\{2, 5, 8, 11\}$), ghép nối và chiếu chúng qua một phép biến đổi tuyến tính, căn chỉnh lại theo lưới không gian (spatial grid alignment) để tạo thành $G'$, rồi tiêm phần dư (residual-inject) trực tiếp trở lại chuỗi token thị giác $T$ ngay trước bộ giải mã theo phương trình:

$$\hat{T} = T + \lambda G'$$

Phương trình trên của SARA chính là hiện thân toán học chuẩn xác nhất của đường truyền tắt (skip connection) kiểu U-Net trong kiến trúc Transformer đa phương thức.

## 4. Làm rõ bản chất của PaddleOCR-VL-1.6 và ParseFixer

Hai điểm kỹ thuật cuối cùng cần được hiệu chỉnh liên quan đến cơ chế tinh chỉnh vùng và sửa lỗi hậu kỳ. Trong **PaddleOCR-VL-1.6** (công bố cuối tháng 5 / đầu tháng 6/2026, đạt kỷ lục SOTA 96,33\% trên OmniDocBench v1.6), thuật ngữ *Under-Optimized Region Refinement* hoàn toàn không phải là một nhánh mạng dự đoán độ lệch tọa độ ($\Delta x, \Delta y, \Delta w, \Delta h$) trong lúc suy luận. Thực chất, PaddleOCR-VL-1.6 giữ nguyên hoàn toàn kiến trúc $0,9\text{B}$ siêu nhẹ của phiên bản 1.5, bao gồm bộ mã hóa thị giác độ phân giải gốc kiểu NaViT, bộ kết nối Adaptive MLP và mô hình ngôn ngữ ERNIE-4.5-0.3B đi kèm tầng bố cục PP-DocLayoutV3. Đột phá của phiên bản 1.6 nằm ở quy trình khai phá dữ liệu ngoại tuyến: hệ thống xác định các "vùng thưa độ phủ" (Coverage-Sparse Regions) mà mô hình cũ xử lý kém (như sách cổ, ký tự hiếm, bảng công nghiệp phức tạp), sau đó sử dụng tổ hợp các mô hình chuyên gia $\{E_1, E_2, E_3\}$ cùng mô hình thẩm định $M$ qua tối đa $T$ vòng lặp để gán nhãn tự động và chọn lọc mẫu giá trị cao đưa vào huấn luyện tăng cường (Reinforcement Learning).

Song song đó, đối với **ParseFixer** (*An Agentic Framework for Document Parsing via Selective Multimodal Correction*, tháng 6/2026), khung làm việc này bao gồm hai mô-đun là **Full-Page Backbone Parsing (FBP)** thực hiện giải mã toàn trang mặc định ($Y_0$), và **Agentic Selective Correction (ASC)** chỉ kích hoạt khi phát hiện lỗi định dạng rõ rệt. ASC sử dụng các bộ kích hoạt cấp trang ($c_i^p \in \{0, 1\}$ cho lỗi cụt cấu trúc hoặc rối loạn toàn cục) và cấp phần tử (như kiểm tra dấu ngoặc nhọn không cân bằng, môi trường LaTeX sai lệch thông qua hàm sửa lỗi tiền định $\tilde{F}_{i,j} = \rho_{\text{latex}}(F^0_{i,j})$, hoặc nâng cấp khối văn bản thành bảng giả

*pseudo-table* nếu phát hiện cấu trúc bảng không viền) trước khi gọi mô hình đa phương thức sửa lại và kiểm chứng (verify-and-rollback). Việc áp dụng triết lý kiểm chứng - quay lui của ParseFixer vào bước cuối của hệ thống lắp ráp là cực kỳ giá trị, nhưng cần dựa trên các bộ kiểm tra cú pháp tiền định thay vì phụ thuộc vào quy tắc tăng nhiệt độ ngẫu nhiên chưa được kiểm chứng.

# Bản Đồ Các Công Trình Tiên Phong Và Định Vị Đóng Góp Học Thuật

Để định vị chính xác tính mới (novelty) của ý tưởng đề xuất, cần đặt nó trong bức tranh toàn cảnh của các hệ thống giải mã tài liệu tiên tiến nhất giai đoạn 2025–2026. Xu hướng lớn của ngành hiện nay đang dịch chuyển từ việc dùng một VLM khổng lồ đọc tuần tự cả trang sang các cơ chế phân tách phân cấp (coarse-to-fine decoupling) hoặc điều kiện hóa theo vùng (region-anchored parsing).

| Hệ thống / Công trình | Quy mô tham số | Cơ chế xử lý bố cục & Thứ tự đọc | Cơ chế nhận dạng & Giải mã | Điểm tương đồng với ý tưởng đề xuất | Điểm khác biệt cốt lõi so với kiến trúc hướng tới |
|---|---|---|---|---|---|
| **PaddleOCR-VL-1.6** (2026) | 33M (Layout) + 0.9B (VLM) | Ngoại vi tường minh qua PP-DocLayout V3 (bbox, đa giác, mặt nạ, thứ tự đọc). | Cắt ảnh từng phần tử \rightarrow định tuyến prompt chuyên biệt \rightarrow ERNIE-4.5-0.3B VLM. | Cùng dùng PP-DocLayout V3 làm mỏ neo hình học và định tuyến theo loại vùng. | Không có cơ chế causal-flow queries của DeepSeek; cắt ảnh rời rạc làm mất ngữ cảnh toàn trang. |
| **DeepSeek-OCR 2** (01/2026) | ~3B (DeepEncoder V2 + LLM) | Nội sinh ngầm định: 256 \sim 1120 causal-flow queries tự học thứ tự đọc 2D qua Qwen2-0.5B. | Toàn trang + tối đa 6 vùng cắt 768\times768 đưa vào bộ giải mã LLM. | Nền tảng bộ mã hóa/giải mã nhân quả thị giác. | Thiếu thông tin hình học/đa giác tường minh từ bộ phát hiện chuyên dụng bên ngoài. |
| **Dolphin / Dolphin-v2** (ByteDance, 2025–2026) | 322M (v1) / 3B (v2) | Giai đoạn 1: Cùng VLM sinh chuỗi phần tử bố cục theo thứ tự đọc tự nhiên. | Giai đoạn 2: Dùng phần tử làm mỏ neo không đồng nhất (heterogeneous anchors), cắt ảnh giải mã song song. | Mô hình "phân tích trước, giải mã sau" với mỏ neo bố cục và prompt chuyên biệt. | Mỏ neo sinh nội bộ bởi Swin+mBART (hoặc VLM), không kết hợp Paddle + DeepSeek hay kết nối tắt U-Net. |
| **MinerU2.5** (09/2025) | 1.2B (Decoupled VLM) | Phân tích bố cục toàn cục trên ảnh độ | Nhận dạng chi tiết trên các vùng cắt ở độ | Tư duy tách biệt ngữ cảnh toàn cục và chi | Không sử dụng truy vấn luồng nhân quả hay |

| Hệ thống / Công trình | Quy mô tham số | Cơ chế xử lý bố cục & Thứ tự đọc | Cơ chế nhận dạng & Giải mã | Điểm tương đồng với ý tưởng đề xuất | Điểm khác biệt cốt lõi so với kiến trúc hướng tới |
|---|---|---|---|---|---|
| | | phân giải thấp. | phân giải gốc (native-resolution crops). | tiết cục bộ. | tích hợp đa mô hình không huấn luyện. |
| **Youtu-Parsing** (Tencent, 2025–2026) | MLLM (Dynamic ViT) | Mã hóa toàn trang 1 lần tạo biểu diễn thị giác dùng chung (shared features). | Giải mã theo vùng được nhắc bằng tọa độ bbox (region-prompted decoding), song song 5 hộp. | Gần nhất với ý tưởng "mã hóa cả trang 1 lần rồi dùng bbox truy vấn vào đặc trưng". | Không dùng mỏ neo đa giác từ PP-DocLayout V3 để điều kiện hóa causal-flow queries. |
| **PaDoc** (08/2026) | ~2B (Single MLLM) | Tiền tố ảnh và cây bố cục chung (shared layout prefix). | Mặt nạ chú ý tổ tiên (ancestor attention) + giải mã phân nhánh song song ([fork] tokens). | Tối ưu hóa việc chia sẻ ngữ cảnh toàn trang khi giải mã song song các vùng. | Là cơ chế phân nhánh tự hồi quy trên cây, không phải đường truyền tắt đặc trưng thị giác kiểu U-Net. |
| **Read, Parse, Describe (SARA)** (10/2026) | Qwen3.5-2B (Frozen) + 83.99M Adapter | Tự hồi quy xuất đồng thời bbox, nhãn, thứ tự đọc, văn bản và mô tả ảnh. | Trích xuất đặc trưng tầng \{2, 5, 8, 11\}, căn chỉnh lưới và cộng phần dư \hat{T} = T + \lambda G'. | Hiện thực hóa chuẩn xác nhất kết nối tắt không gian kiểu U-Net trong Transformer. | Không sử dụng bộ phát hiện bố cục tường minh bên ngoài (như PP-DocLayout V3) làm tín hiệu điều khiển. |
| **LayTextLLM** (ACL 2025) | Llama2-7B + SLP + P-LoRA | Nhận tọa độ OCR có sẵn, chiếu mỗi bbox thành 1 token qua MLP 2 tầng (SLP). | Đan xen token bbox và token văn bản (interleaving) để giải quyết KIE và VQA. | Chứng minh một hộp giới hạn có thể nén thành vector nhúng đưa vào LLM. | Không có bộ mã hóa thị giác (chỉ dùng tọa độ + văn bản OCR, yếu trên ChartQA); bắt buộc phải huấn luyện SLP. |

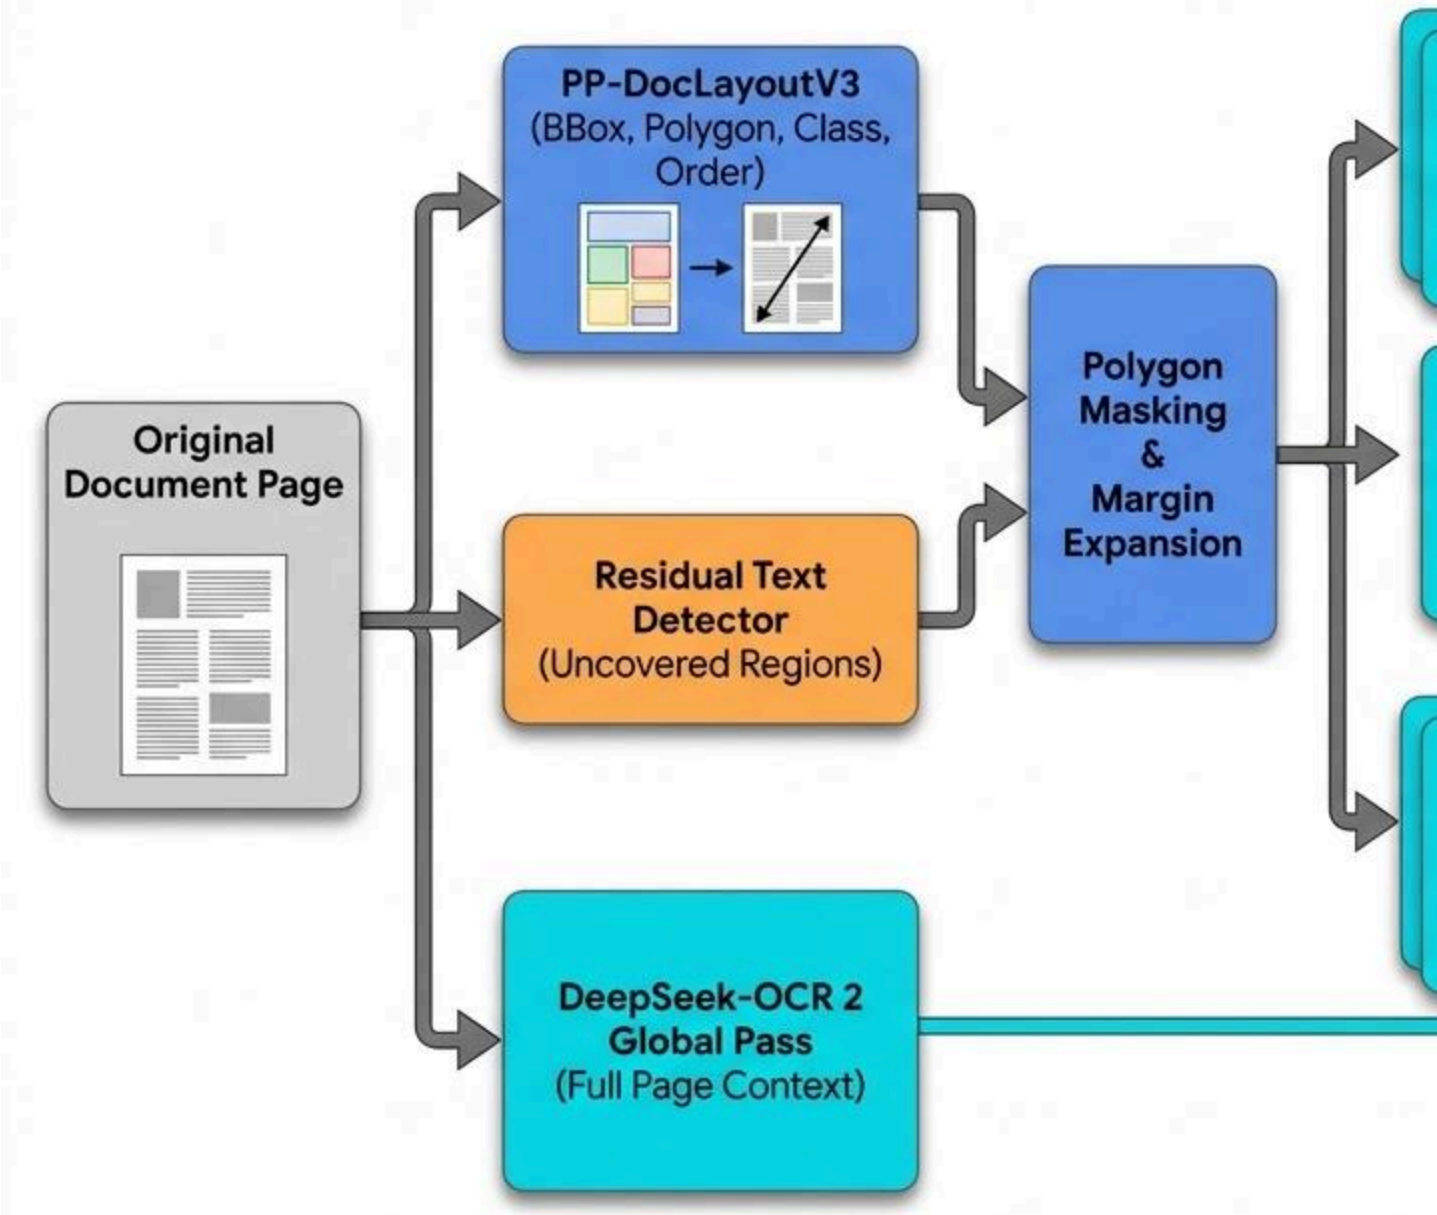
## Phân Tích Các Quan Hệ Nhân Quả Giữa Hình Học Tường Minh Và Suy Luận Ngầm Định

Từ dữ liệu thực nghiệm của các công trình trên, có thể rút ra ba quy luật quan trọng định hình thiết kế hệ thống. Thứ nhất, cắt ảnh vật lý (element cropping) vượt trội hơn truy vấn tọa độ thô (box query) khi không có tầng căn chỉnh không gian chuyên sâu. Nghiên cứu ablation của **Dolphin** chỉ ra một con số đặc biệt quan trọng: việc cắt trực tiếp phần tử ảnh để đưa vào bộ giải mã đạt khoảng cách chỉnh sửa (Edit Distance - ED) là 0,1283, tốt hơn đáng kể so với mức 0,1849 ED khi giữ nguyên ảnh toàn trang và dùng truy vấn tọa độ (box-based queries). Đồng

thời, việc sử dụng prompt chuyên biệt theo từng loại phần tử (heterogeneous anchor prompting: dùng P_{\text{table}} xuất HTML cho bảng, P_{\text{paragraph}} xuất văn bản và LaTeX cho đoạn văn/công thức) giúp giảm lỗi từ 0,1613 ED (prompt chung) xuống 0,1283 ED, đồng thời giải mã song song giúp tăng tốc 1,8\times (0,1729 so với 0,0971 FPS). Điều này giải thích tại sao ở giai đoạn lắp ráp không huấn luyện, việc dùng tọa độ từ PP-DocLayoutV3 để cắt ảnh và định tuyến prompt cho DeepSeek-OCR 2 sẽ mang lại hiệu quả tức thì và ổn định hơn nhiều so với việc cố gắng nhồi tọa độ số vào không gian ẩn.
Thứ hai, bổ sung thông tin bố cục tường minh chỉ có ích khi cơ chế hợp nhất không làm nhiễu khả năng suy luận tự nhiên của VLM. Công trình **Qianfan-OCR** (2026) thử nghiệm cơ chế *Layout-as-Thought* (yêu cầu mô hình tự sinh tọa độ bbox, loại phần tử và thứ tự đọc như một chuỗi suy nghĩ trước khi xuất văn bản cuối cùng), nhưng kết quả cho thấy việc ép mô hình xuất tọa độ tường minh không phải lúc nào cũng làm tăng điểm tổng thể. Tương tự, trên bảng xếp hạng **OmniDocBench v1.6**, các mô hình chuyên biệt có kích thước nhỏ gọn nhưng được tối ưu hóa tốt sự phối hợp giữa bố cục và nhận dạng như **PaddleOCR-VL-1.6** (0,9\text{B} tham số, đạt 96,33\% tổng thể, Text Edit 0,035, Formula CDM 94,21\%, Table TEDS 92,76\% ở bản 1.5) hoàn toàn vượt qua các mô hình đa phương thức khổng lồ chạy toàn trang như **InternVL3.5-241B** (83,76\%, RO Edit 0,215), **Kimi K2.5 1T** (84,53\%, RO Edit 0,211), **GPT-5.2** (86,59\%, RO Edit 0,193), **Qwen3-VL-235B** (89,78\%, RO Edit 0,166), **Gemini 3 Flash** (92,62\%, RO Edit 0,172), **Gemini 3 Pro** (92,91\%, RO Edit 0,165), hay **Ovis2.6-30B-A3B** (93,70\%, RO Edit 0,135). Ngay cả khi thay đổi tầng bố cục phía trước cùng một bộ nhận dạng (ví dụ ghép với MinerU2.5 hoặc PaddleOCR-VL-1.5-0.9B), việc nâng cấp từ DocLayout-YOLO lên RT-DocLayout (PP-DocLayoutV3) đã kéo điểm tổng thể từ 87,29\% lên 94,50\% và giảm lỗi thứ tự đọc từ 0,169 xuống 0,042.
Thứ ba, định vị đóng góp học thuật (Research Contribution) của kiến trúc đề xuất không nên dừng ở tuyên bố chung là "kết hợp bộ phát hiện bố cục với VLM", bởi hướng tiếp cận vĩ mô đó đã được khai phá bởi Dolphin, MinerU2.5, PaddleOCR-VL và Youtu-Parsing. Thay vào đó, tính mới độc đáo và chưa từng có công trình nào công bố tính đến tháng 10/2026 nằm ở sự hợp nhất bốn cơ chế trong một khung lý thuyết duy nhất:
\[span_60](start_span)[span_60](end_span)[span_62](start_span)[span_62](end_span)boxed{\text{Neo hình học tường minh PP-DocLayoutV3} + \text{Luồng nhân quả DeepSeek} + \text{Kết nối tắt không gian kiểu SARA} + \text{Phục hồi vùng dư toàn cục}}
Cụ thể, luận điểm khoa học trung tâm là sử dụng các tiên nghiệm hình học và thứ tự đọc tường minh từ một bộ phát hiện siêu nhẹ bên ngoài (PP-DocLayoutV3) làm tín hiệu điều khiển (control signal) để điều kiện hóa các truy vấn luồng nhân quả (causal-flow queries) của DeepSeek-OCR 2, đồng thời bảo toàn ngữ cảnh toàn trang và khôi phục bằng chứng không gian đa tỷ lệ thông qua đường truyền tắt phần dư kiểu U-Net/SARA.

# Thiết Kế Kiến Trúc Giai Đoạn 1: Lắp Ráp Module Không Huấn Luyện (Zero-Training POC)

Với mục tiêu trọng tâm ở giai đoạn hiện tại là lắp ráp các mô hình có sẵn để kiểm chứng giả thuyết mà không phải huấn luyện lại trọng số, toàn bộ ý tưởng "Vision Encoder toàn trang + BBox & Reading Order từ Paddle + Tạo Query kết hợp + Giải mã ngược kiểu U-Net" cần được ánh xạ sang một kiến trúc điều phối hai luồng Toàn cục - Cục bộ (Dual-Stream Global-Local Orchestration Pipeline). Kiến trúc này cho phép kiểm chứng từ 70\% đến 80\% giá trị cốt lõi của giả thuyết nghiên cứu bằng các checkpoint công khai trước khi đầu tư tài nguyên viết tầng Adapter.




## 1. Chuẩn Hóa Hệ Tọa Độ Và Trích Xuất Mỏ Neo Hình Học Bằng

## PP-DocLayoutV3

Một trong những nguyên nhân gây lỗi phổ biến nhất trong các hệ thống lắp ráp đa mô hình là sự lệch hệ quy chiếu tọa độ khi các dịch vụ khác nhau tự ý thay đổi kích thước ảnh (resize/padding). Do đó, ngay khi chuyển đổi trang PDF hoặc ảnh chụp tài liệu đầu vào $I \in \mathbb{R}^{H \times W \times 3}$, hệ thống điều phối phải thiết lập một hệ tọa độ chuẩn duy nhất và lưu trữ song song cả tọa độ điểm ảnh tuyệt đối lẫn tọa độ chuẩn hóa:
$B_k^{\text{px}} = (x_1, y_1, x_2, y_2), \quad B_k^{\text{norm}} = \left(\frac{x_1}{W}, \frac{y_1}{H}, \frac{x_2}{W}, \frac{y_2}{H}\right)$
Khi đưa ảnh $I$ qua mô hình PaddlePaddle/PP-DocLayoutV3 (thực thi trên GPU hoặc qua OpenVINO ở kích thước chuẩn hóa nội bộ $800 \times 800$ kèm hệ số tỷ lệ $scale_factor \left[\frac{800}{H}, \frac{800}{W}\right]$ và ngưỡng lọc $draw_threshold = 0.5$), mô hình trả về tập hợp các vùng bố cục $\mathcal{R} = \{R_1, \dots, R_N\}$, trong đó mỗi vùng được định nghĩa bởi bộ năm tham số:
$R_k = (B_k, M_k, C_k, O_k, s_k)$
Ở đây, $B_k$ là hộp giới hạn chữ nhật, $M_k$ là đa giác nhiều điểm (multi-point polygon) hoặc mặt nạ điểm ảnh bám sát đường viền thực tế của văn bản, $C_k$ là nhãn phân loại bố cục (như text, title, table, display_formula, chart, seal, list, caption), $O_k$ là chỉ số thứ tự đọc đã được sắp xếp hợp lý, và $s_k$ là độ tự tin của dự đoán.

## 2. Cơ Chế Phục Hồi Vùng Dư Không Huấn Luyện (Zero-Training Residual Region Detector)

Để hiện thực hóa ý tưởng "Global Residual Queries" (cứu các vùng thông tin mà bộ phát hiện bố cục bỏ sót) ngay trong giai đoạn không huấn luyện, hệ thống không thể tạo truy vấn học sẵn trong mạng nơ-ron, nhưng hoàn toàn có thể giải quyết bằng thuật toán hình học trên đầu ra của một bộ phát hiện dòng văn bản thuần túy (pure text detector) chạy song song, ví dụ mô-đun phát hiện văn bản nhẹ trong hệ sinh thái PaddleOCR như PP-OCRv5/v6.
Giả sử bộ phát hiện văn bản thuần túy tìm thấy tập các hộp dòng chữ $T = \{t_1, \dots, t_m\}$ trên toàn trang. Với mỗi hộp văn bản $t_j$, hệ thống tính toán tỷ lệ diện tích được bao phủ bởi hợp của tất cả các hộp bố cục $B_k$ do PP-DocLayoutV3 sinh ra:
$\operatorname{coverage}(t_j) = \frac{\operatorname{area}\left(t_j \cap \bigcup_{k=1}^{N} B_k\right)}{\operatorname{area}(t_j)}$
Nếu $\operatorname{coverage}(t_j) < \tau$ (với ngưỡng $\tau \in [0.5, 0.7]$ được tinh chỉnh qua thực nghiệm), hộp $t_j$ được xác định là một vùng văn bản bị PP-DocLayoutV3 bỏ sót, vốn thường gặp ở các ghi chú lề, số trang, công thức nội dòng tách biệt, hoặc các ô đánh dấu biểu mẫu nhỏ. Các hộp $t_j$ chưa được bao phủ nằm gần nhau về mặt không gian sẽ được gom cụm (clustering) thành các vùng dư $R^{\text{residual}}_1, \dots, R^{\text{residual}}_m$, chèn vào danh sách vùng cần nhận dạng và nội suy thứ tự đọc dựa trên tọa độ hình học tương đối so với các vùng $R_k$ lân cận. Cơ chế này mô phỏng hoàn hảo triết lý "Neo hộp + Phục hồi phần dư không neo" mà không cần huấn luyện bất kỳ tham số nào.

## 3. Kỹ Thuật Cắt Ảnh Mở Rộng Biên Và Che Mặt Nạ Đa Giác (Polygon Masking)

Khi chuyển đổi từng vùng $R_k$ thành ảnh con $I_k$ để đưa vào bộ nhận dạng cục bộ, việc cắt sát mép hộp giới hạn $B_k$ thường xuyên làm mất dấu câu, chỉ số trên/dưới (superscript/subscript)

của công thức toán học, hoặc đường viền ngoài của bảng biểu. Ngược lại, nếu mở rộng hộp giới hạn chữ nhật trên các tài liệu bị nghiêng, cong vênh hoặc bố cục đa cột sát nhau, vùng ảnh cắt của một đoạn văn có thể dính thêm một phần tiêu đề hoặc chữ của cột bên cạnh.
Để giải quyết triệt để bài toán này, quy trình cắt ảnh cần kết hợp đồng thời kỹ thuật mở rộng biên có kiểm soát (margin expansion) và kỹ thuật che mặt nạ đa giác (polygon masking). Cụ thể, hệ thống mở rộng hộp giới hạn $B_k$ theo tỷ lệ $\delta \in \{0, 0.02, 0.05, 0.10\}$ kích thước hộp để tạo vùng đệm $B'_k = \operatorname{expand}(B_k, \delta)$ bảo toàn trọn vẹn nét chữ ngoài rìa. Ngay sau đó, hệ thống tận dụng chính đa giác nhiều điểm hoặc mặt nạ $M_k$ mà PP-DocLayoutV3 cung cấp (theo đúng kỹ thuật đã được chứng minh hiệu quả trong mã nguồn của GLM-OCR và dự án Docling khi tích hợp PP-DocLayoutV3): thực hiện cắt theo hộp chữ nhật bao ngoài (Axis-Aligned Bounding Box crop), nhưng tô trắng (white-out) toàn bộ các điểm ảnh nằm ngoài đa giác $M_k$ mở rộng nhẹ. Sự kết hợp này vừa giữ được ngữ cảnh viền cho ký tự, vừa loại bỏ hoàn toàn nhiễu văn bản từ các vùng lân cận bị lọt vào khung chữ nhật khi tài liệu bị nghiêng hoặc uốn cong.

## 4. Điều Kiện Hóa DeepSeek-OCR 2 Ở Mức Đầu Vào Và Nhánh Toàn Cục Song Song

Trong giai đoạn không huấn luyện, việc "tạo query từ vector thị giác + vector bounding box" được thực hiện thông qua cắt ảnh vật lý kết hợp định tuyến prompt chuyên biệt theo nhãn bố cục (Task-Routed Heterogeneous Prompting) vào mô hình deepseek-ai/DeepSeek-OCR-2. Ở mức độ này, mỗi ảnh cắt $I_k$ đi vào DeepSeek-OCR 2 sẽ được DeepEncoder V2 phân tích bằng toàn bộ năng lực của chuỗi causal-flow queries mà không gặp bất kỳ xung đột không gian tiềm ẩn nào.
Bảng dưới đây quy định cấu hình định tuyến prompt và siêu tham số suy luận cho từng nhánh xử lý của DeepSeek-OCR 2 dựa trên nhãn $C_k$ từ PP-DocLayoutV3 và tài liệu chuẩn của mô hình.

| Loại vùng / Nhánh xử lý ($C_k$) | Chế độ / Cấu hình Prompt gửi vào DeepSeek-OCR 2 | Định dạng đầu ra mục tiêu | Độ phân giải & Ngân sách Token thị giác | Ghi chú kỹ thuật & Xử lý hậu kỳ |
|---|---|---|---|---|
| **text / title / caption / list** | Chế độ nhận dạng văn bản trung thực, bảo toàn ngắt dòng có ý nghĩa (Free OCR. hoặc prompt nhận dạng đoạn văn). | Văn bản thuần / Markdown cơ bản | 1024 \times 1024 (256 tokens) cho đoạn ngắn; thêm crop 768 \times 768 nếu khối văn bản rất dài. | Nhiệt độ Temperature = 0.0 để tránh ảo giác từ vựng. |
| **display_formula / inline_formula** | Prompt chuyên biệt chuyển đổi công thức toán học sang mã LaTeX chuẩn, nghiêm cấm sinh lời giải thích. | Chuỗi LaTeX ( ... hoặc ...) | 1024 \times 1024 (256 tokens). | Đi qua hàm tiền định \rho_{\text{latex}} để cân bằng dấu ngoặc {} và \left/\right. |
| **table** | Prompt tái cấu trúc bảng biểu sang Markdown hoặc | HTML <table> hoặc Markdown Table | Động: (0\text{--}6) \times 768 \times 768 + 1 \times | DeepEncoder V2 đặc biệt mạnh khi liên kết tiêu đề |

| Loại vùng / Nhánh xử lý (C_k) | Chế độ / Cấu hình Prompt gửi vào DeepSeek-OCR 2 | Định dạng đầu ra mục tiêu | Độ phân giải & Ngân sách Token thị giác | Ghi chú kỹ thuật & Xử lý hậu kỳ |
|---|---|---|---|---|
| | HTML có cấu trúc, giữ nguyên quan hệ hàng/cột và ô gộp. | | 1024 \times 1024 (256 \sim 1120 tokens). | bảng với ô dữ liệu trong bảng không viền. |
| **chart / figure** | Chế độ phân tích hình ảnh (Parse the figure. hoặc Describe th[span_84](start_span)[span_84](end_span)is image in detail.). | JSON / Mô tả cấu trúc hoặc bảng dữ liệu trích xuất | 1024 \times 1024 + các vùng cắt cục bộ nếu biểu đồ nhiều chi tiết nhỏ. | Đáp ứng tiêu chuẩn liên kết chú thích và văn bản thay thế (alt-text) của Read-Parse-Describe. |
| **unknown / residual** (Từ bộ dò vùng dư) | Prompt hai bước: xác định nhãn ngữ nghĩa của vùng, sau đó phiên dịch chính xác nội dung bên trong. | JSON {"refined_label": "...", "content": "..."} | 1024 \times 1024 (256 tokens). | Cứu các vùng bị PP-DocLayoutV3 bỏ sót (\operat[span_201](start_span)[span_201](end_span)orname{coverage}(t_j)[span_88](start_span)[span_88](end_span)[span_94](start_span)[span_94](end_span)< \tau). |
| **Nhánh Toàn Trang (Y^{\text{global}})** | Chế độ tài liệu có neo: \n<\|grounding\|>Convert the document to markdown.. | Markdown toàn trang có cấu trúc | Tối đa 6 \times 768 \times 768 + 1 \times 1024 \times 1024 (1120 tokens). | Chạy song song 1 lần cho cả trang I để giữ ngữ cảnh toàn cục và kiểm tra chéo. |

Các vùng cục bộ độc lập R_[span_89](start_span)[span_89](end_span)[span_95](start_span)[span_95](end_span)1, \dots, R_N hoàn toàn có thể được gom lô (batching) theo từng nhóm tác vụ (text batch, table batch, formula batch) và thực thi bất đồng bộ (asyncio.gather hoặc qua SGLang/vLLM) để khai thác triệt để lợi thế tăng tốc của giải mã song song tương tự như Dolphin và PaDoc. Song song đó, lượt chạy toàn trang Y^{\text{global}} = \operatorname{DSOCR2}(I) đóng vai trò như "nhánh truyền thẳng toàn cục": nó giữ lại cái nhìn tổng thể của DeepEncoder V2 trên toàn bộ bức ảnh gốc, giúp phát hiện các lỗi cắt đứt câu giữa hai cột, lỗi gộp nhầm hộp, hoặc làm nguồn tham chiếu khi một vùng cắt cục bộ sinh ra kết quả bất thường.

## 5. Đối Chiếu Ngữ Nghĩa, Điểm Tin Cậy Và Kiểm Chứng - Quay Lui (Verify-and-Rollback)

Để hiện thực hóa ý tưởng "suy luận ngược ra từ decoder cộng với bbox để gán nhãn rồi xuất ra ngược lại" mà không làm hỏng tọa độ hình học chuẩn của PP-DocLayoutV3, hệ thống không bắt bộ giải mã LLM phải hồi quy lại tọa độ số, mà yêu cầu bộ giải mã xác nhận hoặc tinh chỉnh nhãn ngữ nghĩa ($C_k^{\text{VLM}}$) đi kèm nội dung nhận dạng ($Y_k$).
Sau khi thu nhận kết quả từ nhánh cục bộ $L_k = (B_k, C_k^{\text{layout}}, O_k, Y_k, C_k^{\text{VLM}})$ và nhánh toàn cục $G = Y^{\text{global}}$, tầng Đối chiếu và Kiểm chứng (Reconciliation & Verify-and-Rollback) tiến hành quy trình kiểm tra đa tầng. Bước đầu tiên là đối chiếu xung đột nhãn ngữ nghĩa (semantic label reconciliation): nếu $C_k^{\text{layout}} = C_k^{\text{VLM}}$, hệ thống chốt nhãn cuối cùng $C_k^{\text{final}} = C_k^{\text{layout}}$. Nếu xảy ra bất đồng — chẳng hạn PP-DocLayoutV3 gán nhãn text nhưng VLM hoặc bộ chẩn đoán phát hiện cấu trúc bảng không viền (*pseudo-table*) hoặc công thức toán học (*pseudo-formula*) — hệ thống lập tức gắn cờ layout_vlm_label_disagreement và tự động nâng cấp vùng đó sang quy trình xử lý chuyên biệt tương ứng.
Bước tiếp theo là tính toán điểm định tuyến tổng hợp (routing confidence score) cho từng vùng k bằng cách chuẩn hóa chuỗi văn bản và dùng thuật toán căn chỉnh chuỗi (sequence alignment / fuzzy matching) để đo mức độ nhất quán giữa nội dung cục bộ $Y_k$ và văn bản toàn trang G: $S_k = w_l s_k^{\text{layout}} + w_g s_k^{\text{global-consistency}} + w_v s_k^{\text{validation}}$ Trong biểu thức trên, thành phần $s_k^{\text{validation}}$ được xác định bằng các bộ kiểm tra cú pháp tiền định cực nhanh theo cơ chế Agentic Selective Correction (ASC) của ParseFixer. Đối với công thức LaTeX, hệ thống kiểm tra tính cân bằng của dấu ngoặc nhọn { }, cặp lệnh \left / \right, tính hợp lệ của môi trường \begin / \end, và áp dụng hàm sửa lỗi tiền định $\tilde{F}_{i,j} = \rho_{\text{latex}}(F^0_{i,j})$ để chuẩn hóa dấu phân cách hoặc thoát ký tự tiền tệ mà không cần gọi lại mô hình lớn. Đối với bảng biểu HTML hoặc Markdown, đầu ra được đưa qua bộ phân tích cú pháp DOM để kiểm tra sự cân bằng của các thẻ đóng mở và tính toàn vẹn của cấu trúc hàng cột. Đối với văn bản OCR thông thường, bộ kiểm tra phát hiện các ca rỗng bất thường (khi một vùng có diện tích lớn và điểm tự tin bố cục $s_k^{\text{layout}}$ cao nhưng chỉ xuất ra $0\text{--}1$ ký tự) hoặc lỗi lặp từ vô hạn.
Cuối cùng, cơ chế quyết định định tuyến và quay lui (verify-and-rollback) chỉ kích hoạt nhận dạng lại cục bộ đối với những vùng có điểm $S_k$ thấp hoặc vi phạm quy tắc kiểm tra cú pháp, ví dụ thử lại với biên cắt $\delta$ lớn hơn, đổi sang prompt chuyên biệt khác, hoặc gọi mô hình đối chứng như PaddleOCR-VL-1.6. Nếu kết quả sửa lại vượt qua bước kiểm chứng cú pháp, nó sẽ được chấp nhận để cập nhật vào cấu trúc trang; nếu thất bại, hệ thống quay lui (rollback) về văn bản tương ứng trích xuất từ nhánh toàn cục $Y^{\text{global}}$ nhằm đảm bảo tính an toàn tuyệt đối cho đầu ra. Đầu ra chuẩn tắc (canonical output) của toàn bộ hệ thống được lưu dưới định dạng JSON hợp nhất (chứa đầy đủ id, order, bbox_px, bbox_norm, polygon, layout_label, refined_label, [span_47](start_span)[span_47](end_span)layout_confidence, source, content, structure, và validation_flags), từ đó mới kết xuất (render) sang Markdown, HTML, PDF có thể tìm kiếm hoặc các phân đoạn (chunks) phục vụ hệ thống RAG.

## 6. Kiến Trúc Microservices Cách Ly Môi Trường Và Danh Mục Checkpoint Sẵn Sàng

Một chi tiết kỹ thuật sống còn khi lắp ráp hệ thống này trong thực tế là tuyệt đối không cài đặt tất cả các mô hình vào chung một môi trường ảo Python (single virtual environment). Kho mã nguồn chính thức của DeepSeek-OCR-2 hiện khóa cứng phiên bản thư viện ở mức transformers==4.46.3 và tokenizers==0.20.3, trong khi đường ống PaddleOCR-VL-1.6 yêu cầu paddlepaddle-gpu==3.2.1 (CUDA 12.6),

paddleocr[doc-parser]>=[span_49](start_span)[span_49](end_span)3.6.0 và vllm>=0.11.1. Chính tài liệu kỹ thuật của PaddleOCR và vLLM cũng cảnh báo xung đột phụ thuộc giữa PaddlePaddle và các trình phục vụ VLM, đồng thời khuyến nghị tách rời dịch vụ bố cục và dịch vụ nhận dạng VLM thành các môi trường độc lập giao tiếp qua giao thức HTTP/OpenAI-compatible API.

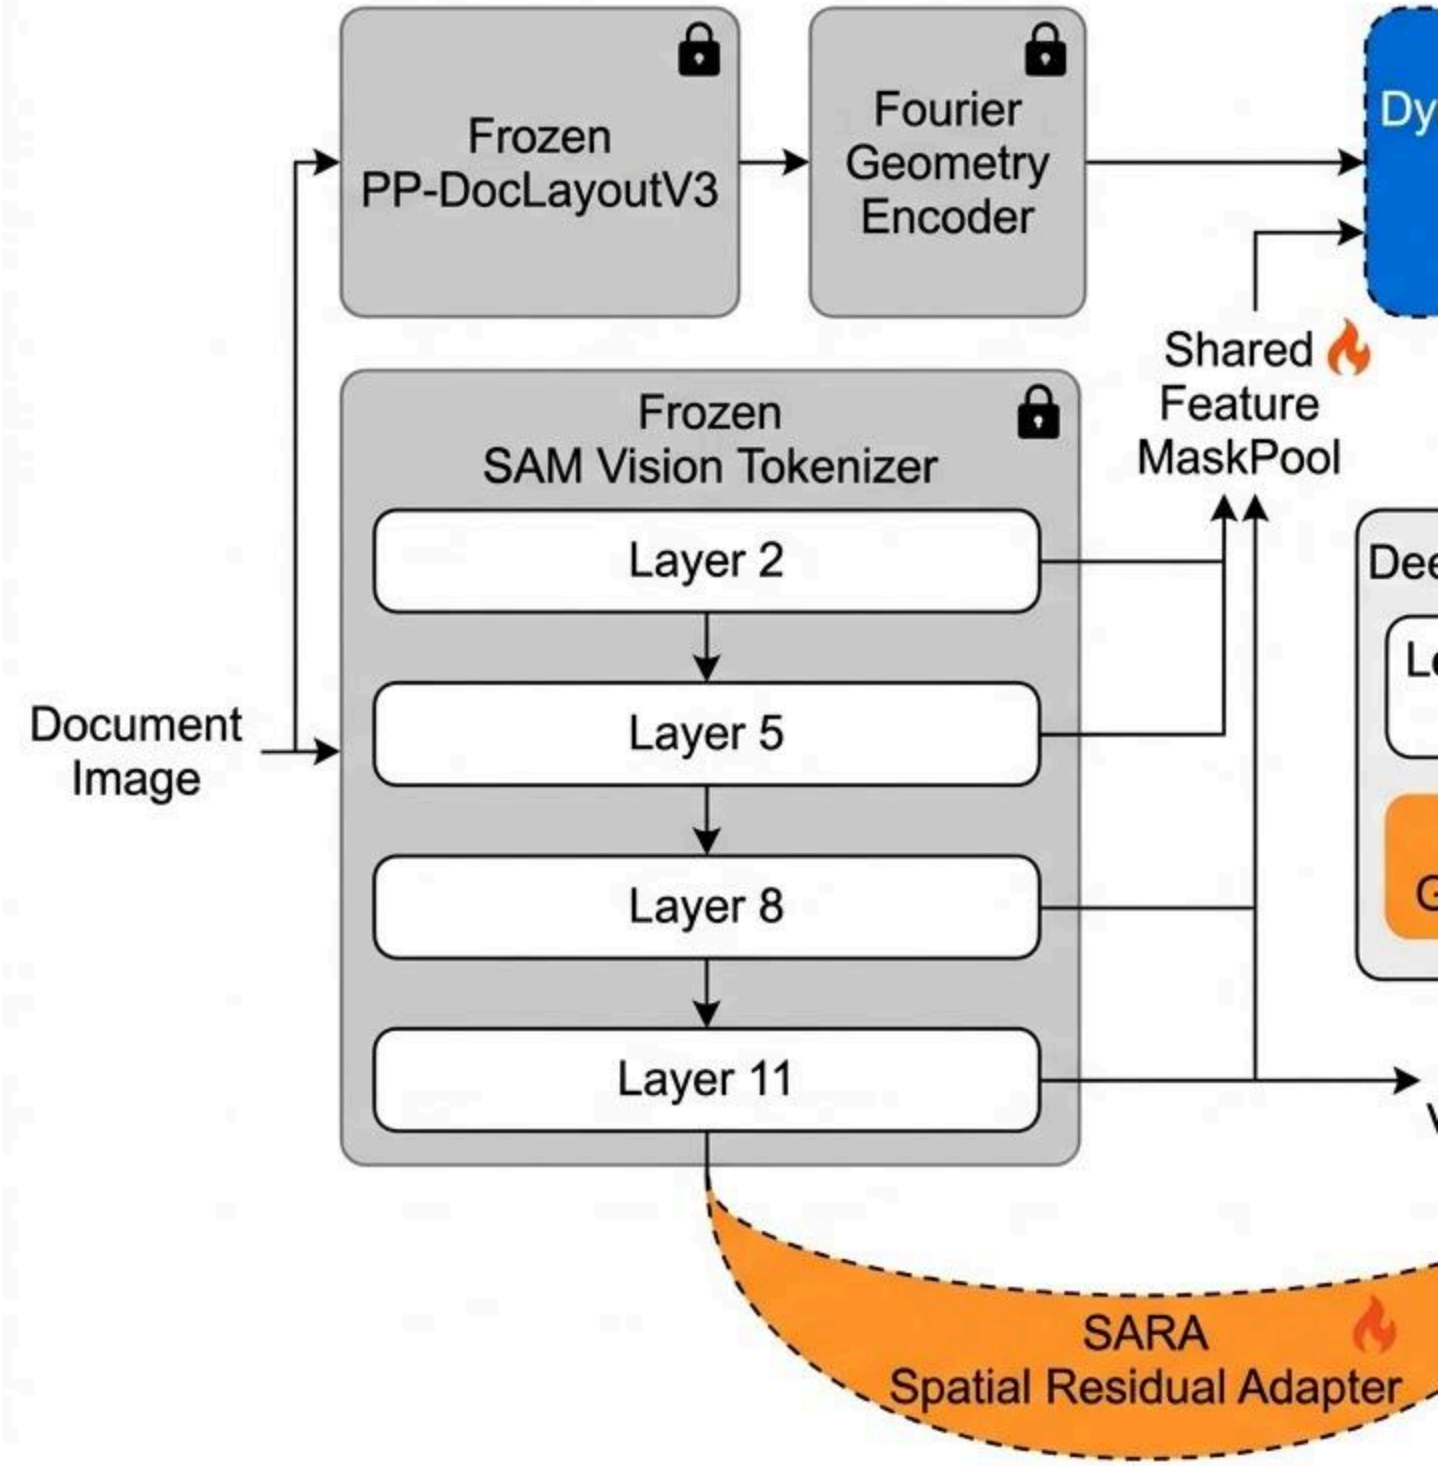
| Vai trò trong hệ thống | Định danh Checkpoint / Kho mã nguồn | Quy mô & Giấy phép | Môi trường thực thi & Lưu ý cấu hình kỹ thuật |
|---|---|---|---|
| **Tầng Bố Cục & Thứ Tự Đọc Chính** | PaddlePaddle/PP-DocLayoutV3 hoặc PP-DocLayoutV3_safetensors | 33M tham số | Dịch vụ layout-svc riêng (paddlepaddle-gpu==3.2.1, paddleocr[doc-parser]>=3.6.0) hoặc chạy qua OpenVINO IR có bật bộ nhớ đệm CACHE_DIR. |
| **Bộ Nhận Dạng Nhân Quả (Cục Bộ & Toàn Trang)** | deepseek-ai/DeepSeek-OCR-2 | ~3B tham số (Apache 2.0) | Dịch vụ deepseek-svc riêng. Khuyên dùng SGLang (--enable-multimodal --tp 1) hoặc vLLM trên 1 GPU hiện đại; nếu chạy Transformers cần trust_remote_code=True, transformers==4.46.3. |
| **Mô Hình Đối Chứng Chuẩn SOTA (Baseline A)** | PaddlePaddle/PaddleOCR-VL-1.6 | 0.9B tham số | Chạy qua vllm serve với cờ --trust-remote-code --max-num-batched-tokens 16384 --no-enable-prefix-caching --mm-processor-cache-gb 0 (tắt bộ đệm tiền tố để tránh chi phí băm ảnh OCR). |
| **Đối Chứng Mỏ Neo Bố Cục Nội Sinh (Baseline F)** | ByteDance/Dolp[span_216](start_span)[span_216](end_span)hin-v2 (hoặc ByteDance/Dolphin 322M) | 3B (v2) / 322M (v1) | Hỗ trợ vLLM, SGLang, TensorRT-LLM; cung cấp cả kịch bản demo_page_hf.py (toàn trang) và demo_element.py (từng phần tử). |
| **Đối Chứng Truy Vấn Vùng Dùng Chung (Baseline G)** | TencentCloudADP/youtu-parsing | MLLM | Kiểm chứng hiệu năng giải mã theo tọa độ hộp giới hạn trên bản đồ đặc trưng thị giác toàn |

| Vai trò trong hệ thống | Định danh Checkpoint / Kho mã nguồn | Quy mô & Giấy phép | Môi trường thực thi & Lưu ý cấu hình kỹ thuật |
|---|---|---|---|
| | | | trang dùng chung. |
| **Đối Chứng Giải Mã Phân Nhánh DAG (Baseline H)** | Longin-Yu/PaDoc | ~2B tham số | Kiểm chứng tốc độ và độ chính xác của cơ chế ancestor-attention và fork-token decoding. |

Trong thiết kế dịch vụ thực tế, một trình điều phối nhẹ (orchestrator) bằng Python sẽ nhận tài liệu, gọi POST /layout tới dịch vụ layout-svc để nhận danh sách đa giác và thứ tự đọc từ PP-DocLayoutV3 cùng các vùng dư, thực hiện cắt ảnh và tô trắng mặt nạ đa giác ngay trong bộ nhớ, sau đó gửi đồng thời các yêu cầu POST /parse-region và POST /parse-page tới dịch vụ deepseek-svc trước khi hợp nhất kết quả. Cách tổ chức kiến trúc hướng dịch vụ này giúp cô lập hoàn toàn xung đột thư viện và cho phép hoán đổi bất kỳ bộ nhận dạng nào để chạy thực nghiệm đối chứng chỉ bằng cách đổi địa chỉ đầu cuối (endpoint).

# Thiết Kế Kiến Trúc Giai Đoạn 2: Điều Kiện Hóa Không Gian Tiềm Ẩn Với Adapter Nhẹ

Khi quy trình lắp ráp ở Giai đoạn 1 đã chứng minh được về mặt thực nghiệm rằng hình học tường minh của PP-DocLayoutV3 kết hợp với luồng nhân quả của DeepSeek-OCR 2 vượt qua các mô hình đơn lẻ, bước tiến hóa tiếp theo là chuyển hóa kiến trúc điều phối bên ngoài đó thành một mô hình tích hợp sâu ở không gian tiềm ẩn (Latent-Space Box-Conditioned & Spatial-Residual Architecture). Tại giai đoạn này, triết lý thiết kế vẫn là đóng băng hoàn toàn (freeze) trọng số của cả PP-DocLayoutV3 lẫn DeepSeek-OCR 2, và chỉ huấn luyện một tập hợp các tầng điều hợp nhẹ (lightweight adapters, ước tính khoảng 50\text{M}\text{--}85\text{M} tham số tương tự quy mô 83,99\text{M} của SARA) thông qua ba cơ chế kết nối phần dư song song.




## 1. Trích Xuất Đặc Trưng Vùng Trên Cùng Bản Đồ Thị Giác Và Mã Hóa Hình Học Fourier

Thay vì sử dụng một bộ mã hóa thị giác độc lập từ bên ngoài rồi ghép nối vector với DeepSeek

(điều gây ra sự lệch pha không gian biểu diễn), kiến trúc Giai đoạn 2 trích xuất đặc trưng vùng quan tâm (RoI) trực tiếp từ các bản đồ đặc trưng trung gian V^{(l)} của chính bộ mã hóa thị giác trong DeepSeek-OCR 2. Cụ thể, khi ảnh toàn trang X đi qua bộ phân tách thị giác dựa trên SAM của DeepSeek tạo ra chuỗi trạng thái ẩn V^{(0)}, V^{(1)}, \dots, V^{(L)}, hệ thống sử dụng mặt nạ đa giác M_k (hoặc hộp B_k) từ PP-DocLayoutV3 đã đóng băng để lấy mẫu đặc trưng ở nhiều tầng trung gian \{l_1, l_2, l_3, l_4\}:
r_k^{(l)} = \operatorname{MaskPool}\left(V^{(l)}, M_k\right) \quad \text{hoặc} \quad r_k^{(l)} = \operatorname{RoIAlign}\left(V^{(l)}, B_k\right) r_k = \operatorname{Concat}\left[r_k^{(l_1)}, r_k^{(l_2)}, r_k^{(l_3)}, r_k^{(l_4)}\right]
Nhờ lấy mẫu trực tiếp trên V^{(l)}, vector r_k tự nhiên nằm trong cùng một không gian đặc trưng thị giác mà DeepEncoder V2 đã được học. Tiếp theo, để biểu diễn hình học chính xác hơn một phép chiếu tuyến tính đơn giản từ 4 tọa độ [x_1, y_1, x_2, y_2] như trong LayTextLLM, hệ thống xây dựng vector hình học mở rộng g_k trên tọa độ chuẩn hóa bao gồm tâm hộp, chiều rộng, chiều cao, tỷ lệ khung hình và diện tích:
g_k = \left[x_c, y_c, w, h, \frac{w}{h}, w \cdot h, x_1, y_1, x_2, y_2\right]
Vector g_k được đưa qua hàm mã hóa tần số Fourier (Fourier positional encoding) \phi(g_k) = \left[\sin(2^j \pi g_k), \cos(2^j \pi g_k)\right]_{j=0}^{J} để nắm bắt các biến thiên không gian tần số cao, sau đó ghép nối với vector nhúng loại phần tử e_k^{\text{type}} = E_c(C_k) và vector nhúng thứ tự đọc e_k^{\text{order}} = E_o(O_k). Toàn bộ thông tin của vùng k được chiếu qua một mạng Adapter nhẹ f_\theta (chỉ gồm LayerNorm -> Linear -> GELU -> Linear):

z_k = f_\theta\left(\left[r_k; \phi(g_k); e_k^{\text{type}}; e_k^{\text{order}}\right]\right)

## 2. Cấp Phát Truy Vấn Động Đa Khe (Dynamic Multi-Slot Allocation) Và Điều Kiện Hóa Có Cổng

Để khắc phục điểm nghẽn dung lượng ngữ nghĩa khi gán cứng "một bounding box bằng một token truy vấn", kiến trúc đề xuất cấp phát cho mỗi vùng B_k một tập hợp gồm K_k token không gian \{z_{k,1}, \dots, z_{k,K_k}\} dựa trên hàm diện tích, loại nhãn ngữ nghĩa và mật độ văn bản K_k = f(\operatorname{area}_k, C_k, \operatorname{density}_k) (ví dụ: tiêu đề nhận 1\text{--}2 khe, đoạn văn và công thức nhận 2\text{--}4 khe, biểu đồ nhận 4\text{--}8 khe, và bảng biểu phức tạp nhận 8\text{--}16 khe thông qua phép lấy mẫu lưới con bên trong \operatorname{RoIAlign}). Tập hợp toàn bộ các token bố cục trên trang tạo thành ma trận Z = [z_1, \dots, z_{N_{\text{slots}}}].
Tại tầng DeepEncoder V2, thay vì xóa bỏ chuỗi truy vấn luồng nhân quả học sẵn Q_0 = [q_1, \dots, q_M] (M \in [256, 1120]), hệ thống giữ nguyên Q_0 và cho phép chúng chú ý chéo (cross-attend) sang ma trận token bố cục Z kèm theo một độ lệch không gian \beta_{jk}^{\text{spatial}} (phụ thuộc vào chỉ số IoU, khoảng cách hình học và thứ tự đọc O_k):
A_{jk} = \operatorname{Softmax}\left(\frac{Q_{0,j} K_k^\top}{\sqrt{d}} + \beta_{jk}^{\text{spatial}}\right) V_k, \quad Q' = Q_0 + \sigma(\gamma) A
Trong đó, \alpha = \sigma(\gamma) là một cổng vô hướng học được (learnable scalar gate) được khởi tạo sao cho \sigma(\gamma) \approx 0 ở thời điểm bắt đầu huấn luyện. Thiết kế khởi tạo bằng không (zero-initialization gating) này mang lại một bảo chứng toán học cực kỳ quan trọng: ở bước huấn luyện đầu tiên, Q' \approx Q_0, tức là mô hình hoạt động y hệt như DeepSeek-OCR 2 nguyên bản mà không hề bị suy giảm hiệu năng do nhiễu từ các tầng khởi tạo ngẫu nhiên; trong quá trình huấn luyện (có thể sử dụng công cụ tối ưu hóa bộ nhớ như Unsloth giúp tăng tốc 1,4\times và giảm 40\% VRAM), cổng \sigma(\gamma) sẽ mở dần để tiêm tín hiệu điều khiển bố cục và thứ tự đọc từ PP-DocLayoutV3 vào luồng nhân quả.

Đồng thời, tập truy vấn Q được chia tách tường minh thành hai nhóm: $Q = [Q^{\text{anchored}}; Q^{\text{global}}]$, trong đó $Q^{\text{anchored}}$ chịu sự điều hướng không gian từ Z, còn $Q^{\text{global}}$ là nhóm truy vấn tự do không bị ràng buộc bởi mặt nạ của PP-DocLayoutV3, đóng vai trò lưới an toàn thu thập mọi chi tiết văn bản bị bộ phát hiện bố cục bỏ sót.

## 3. Đường Truyền Tắt Không Gian Đa Tầng Kiểu U-Net / SARA

Song song với việc điều kiện hóa truy vấn Q', đường truyền tắt U-Net thực thụ từ bộ mã hóa sang bộ giải mã được hiện thực hóa bằng cách tích hợp mô-đun **SARA** trực tiếp lên nhánh token thị giác của DeepSeek. Cụ thể, các bản đồ đặc trưng trung gian từ bốn tầng sớm và giữa của bộ mã hóa thị giác $\{V^{(l_1)}, V^{(l_2)}, V^{(l_3)}, V^{(l_4)}\}$ (ví dụ các tầng $\{2, 5, 8, 11\}$ nơi thông tin đường viền ký tự, đường kẻ bảng và cấu trúc không gian cục bộ chưa bị làm mờ bởi phép nén $16\times$) được ghép nối, chiếu qua mạng tuyến tính $P_\theta$ và căn chỉnh lại khớp với lưới không gian của token thị giác cuối cùng $V^{\text{final}}$:
$$G = P_\theta\left(\left[V^{(l_1)}; V^{(l_2)}; V^{(l_3)}; V^{(l_4)}\right]\right), \quad G' = \operatorname{GridAlign}(G)$$
$$\hat{V} = V^{\text{final}} + \lambda G'$$
Trong công trình Read-Parse-Describe (10/2026), việc gắn mô-đun SARA vào mô hình nền Qwen3.5-2B đóng băng đã giúp đạt điểm F1 là 0,9189, mIoU đạt 0,8919, độ chính xác OCR đạt 0,9636 và điểm thứ tự đọc (RO score) đạt tới 0,9774. Khi kết hợp cả $\hat{V}$ (đặc trưng thị giác được khôi phục chi tiết không gian qua kết nối tắt U-Net) và Q' (truy vấn nhân quả được neo bởi PP-DocLayoutV3) đưa vào bộ giải mã DeepSeek, hệ thống đạt được sự thống nhất hoàn chỉnh giữa định vị hình học sắc nét và khả năng đọc hiểu ngữ nghĩa sâu. Về phần giải mã phân nhánh song song ([fork] tokens) của PaDoc, kiến trúc sư hệ thống chỉ nên tích hợp ở giai đoạn 3 sau khi đã chứng minh được độ chính xác của cụm Adapter trên bộ giải mã chuẩn của DeepSeek.

# Kế Hoạch Thực Nghiệm, Ma Trận Ablation Và Tiêu Chí Chuyển Giao Giai Đoạn

Để tránh rơi vào bẫy tối ưu hóa mù quáng — xây dựng một hệ thống phức tạp tốn nhiều tài nguyên tính toán nhưng không vượt qua được các mô hình cơ sở có sẵn — quá trình phát triển cần tuân thủ một giao thức thực nghiệm nghiêm ngặt trên một tập dữ liệu kiểm thử gồm 100 đến 300 trang tài liệu khó. Tập dữ liệu này cần được tuyển chọn có chủ đích bao gồm: bài báo khoa học 2 cột dày đặc công thức, báo chí trình bày phức tạp, bảng tài chính không đường viền (borderless tables), tài liệu quét bị nghiêng/cong vênh hoặc chụp qua màn hình (tương tự chuẩn Real5-OmniDocBench), chú thích chân trang chữ cực nhỏ, biểu mẫu có ô đánh dấu (checkboxes), và đặc biệt là các tài liệu song ngữ Việt - Anh có dấu thanh điệu phức tạp.

## 1. Ma Trận Thực Nghiệm Đối Chứng Bắt Buộc Và Các Thước Đo Đa Chiều

Hệ thống lắp ráp không huấn luyện phải được đặt lên bàn cân so sánh trực tiếp qua 8 cấu hình thực nghiệm chuẩn hóa dưới đây:

| Mã cấu hình | Mô tả luồng kiến trúc thực nghiệm | Mục tiêu kiểm chứng khoa học |
|---|---|---|
| **Cấu hình A** | PaddleOCR-VL-1.6 nguyên bản | Thiết lập mốc chuẩn SOTA hiện |

| Mã cấu hình | Mô tả luồng kiến trúc thực nghiệm | Mục tiêu kiểm chứng khoa học |
|---|---|---|
| | (PP-DocLayoutV3 + ERNIE-4.5-0.3B VLM) | tại (96,33\% trên OmniDocBench v1.6). |
| **Cấu hình B** | DeepSeek-OCR 2 nguyên bản chạy toàn trang (Document Mode) | Đo lường năng lực suy luận nhân quả thị giác nội sinh khi không có bộ phát hiện bố cục ngoài. |
| **Cấu hình C** | PP-DocLayoutV3 \rightarrow Cắt ảnh đa giác \rightarrow DeepSeek-OCR 2 nhận dạng từng vùng \rightarrow Ghép theo thứ tự đọc | Kiểm tra xem việc thay thế bộ nhận dạng của Paddle bằng DeepSeek-OCR 2 có cải thiện độ chính xác nội dung (C[span_198](start_span)[span_198](end_span) > A?) và việc thêm hình học Paddle có thắng DeepSeek toàn trang (C > B?) hay không. |
| **Cấu hình D** | **Cấu hình C** + Nhánh DeepSeek-OCR 2 toàn trang chạy song song + Đối chiếu & Verify-and-Rollback | Kiểm chứng giả thuyết kết hợp ngữ cảnh toàn cục và chi tiết cục bộ (D > C?). |
| **Cấu hình E** | **Cấu hình D** + Bộ phát hiện vùng văn bản dư (Residual Text Coverage Detector, \operatorname{coverage}(t_j) < \tau) | Kiểm chứng giá trị của cơ chế cứu vùng bị bỏ sót không cần huấn luyện (E > D?). |
| **Cấu hình F** | D[span_117](start_span)[span_117](end_span)[span_122](start_span)[span_122](end_span)olphin-v2 (3B) nguyên bản | Đối chứng với kiến trúc mỏ neo bố cục nội sinh hai giai đoạn của ByteDance. |
| **Cấu hình G** | Youtu-Parsing nguyên bản | Đối chứng với cơ chế giải mã theo vùng trên bản đồ đặc trưng toàn trang dùng chung. |
| **Cấu hình H** | PaDoc (~2B) nguyên bản | Đối chứng tốc độ và độ chính xác với cơ chế giải mã phân nhánh cây DAG. |

Trên mỗi cấu hình, việc đánh giá không được phép chỉ dựa vào tỷ lệ lỗi ký tự đơn thuần mà phải đo lường tách biệt trên năm nhóm chỉ số chuẩn của OmniDocBench và Read-Parse-Describe. Nhóm thứ nhất là chất lượng nhận dạng văn bản (text recognition), được đo bằng tỷ lệ lỗi ký tự (CER) và khoảng cách chỉnh sửa chuẩn hóa (NED / Text Edit \downarrow). Nhóm thứ hai là định vị bố cục (layout localization), sử dụng các thước đo Precision, Recall, F1, và mIoU có xét nhãn ngữ nghĩa (category-aware IoU matching). Nhóm thứ ba là thứ tự đọc (reading order), đo bằng điểm thứ tự đọc \text{RO} = 1 - \text{NormalizedEditDistance} hoặc trực tiếp Reading Order Edit Distance (\downarrow). Nhóm thứ tư đánh giá các phần tử có cấu trúc phức tạp (structured elements), bao gồm điểm TEDS và TEDS-S (\uparrow) cho cấu trúc bảng biểu cùng điểm CDM (\uparrow) cho công thức toán học. Cuối cùng, nhóm thứ năm đo lường hiệu năng vận hành hệ thống (system efficiency)

thông qua thời gian xử lý trung bình và P95 trên mỗi trang (sec/page), mức tiêu thụ bộ nhớ đỉnh (VRAM), tổng số token sinh ra trên mỗi trang, số vùng trung bình trên mỗi trang, và tỷ lệ vùng phải kích hoạt nhận dạng lại (retry rate), bởi một đường ống lai rất dễ tăng 1–2 điểm chính xác nhưng lại làm tăng độ trễ lên gấp nhiều lần.

## 2. Tám Thí Nghiệm Ablation Và Phân Loại Lỗi Chi Tiết

Trong quá trình vận hành các Cấu hình C, D và E, nhóm nghiên cứu cần thực hiện tám phép thử cắt bỏ (ablations) được chuẩn hóa trong bảng dưới đây nhằm cô lập và định lượng đóng góp thực sự của từng thành phần lắp ráp trước khi quyết định huấn luyện mô hình.

| Biến số thực nghiệm (Ablation Dimension) | Cấu hình cơ sở (Baseline Setting) | Cấu hình đối chứng (Ablated / Enhanced Setting) | Câu hỏi nghiên cứu & Giả thuyết cần kiểm chứng |
|---|---|---|---|
| **1. Nguồn thứ tự đọc (Reading Order)** | Sắp xếp hình học đơn giản theo tọa độ y/x. | Thứ tự đọc học kết hợp (coupled order) từ PP-DocLayoutV3. | Liệu thứ tự đọc của PP-DocLayoutV3 có thực sự giảm lỗi RO Edit trên bố cục đa cột và tạp chí so với luật tọa độ hay không? |
| **2. Biên mở rộng vùng cắt (\delta)** | Cắt sát mép hộp giới hạn (\delta = 0\%). | Mở rộng biên \delta \in \{2\%, 5\%, 10\%\}. | Tìm điểm cân bằng tối ưu giúp giữ trọn dấu câu, chỉ số công thức và viền bảng mà không làm lọt nhiễu vùng lân cận. |
| 3. Che mặt nạ đa giác (Polygon Masking) | Cắt ảnh theo hộp chữ nhật bao ngoài thông thường (rectangular bbox crop). | Cắt hộp chữ nhật kết hợp tô trắng vùng ngoài đa giác/mặt nạ M_k. | Định lượng mức giảm lỗi CER trên các trang tài liệu bị nghiêng, cong vênh hoặc chụp qua màn hình. |
| **4. Tiên nghiệm nhãn bố cục (Layout Prior)** | Sử dụng chung một prompt OCR tổng quát cho mọi vùng cắt. | Định tuyến prompt chuyên biệt theo nhãn C_k (table, formula, text, code). | Kiểm chứng xem prompt chuyên biệt trên DeepSeek-OCR 2 có tái현 mức giảm lỗi mạnh mẽ như trên Dolphin (0,1613 \rightarrow 0,1283 ED) hay không. |
| **5. Đối chiếu toàn cục (Global Context)** | Chỉ ghép nối kết quả từ các vùng cắt cục bộ (local crops only). | Kết hợp vùng cục bộ với nhánh toàn trang Y^{\text{global}} để đối chiếu và quay lui. | Đánh giá khả năng phát hiện lỗi chia tách/gộp hộp sai và cứu các vùng cục bộ bị suy biến cú pháp. |
| **6. Phục hồi vùng dư (Residual Coverage)** | Chỉ nhận dạng các hộp bố cục do PP-DocLayoutV3 phát hiện. | Bổ sung các cụm hộp văn bản chưa được bao phủ (\operatorname{covera | Đo lường mức cải thiện Recall đối với các chú thích chân trang nhỏ, số tham chiếu và ô biểu |

| Biến số thực nghiệm (Ablation Dimension) | Cấu hình cơ sở (Baseline Setting) | Cấu hình đối chứng (Ablated / Enhanced Setting) | Câu hỏi nghiên cứu & Giả thuyết cần kiểm chứng |
|---|---|---|---|
| | | ge}(t_j) < \tau). | mẫu bị bỏ sót. |
| **7. Bộ nhận dạng cục bộ (Recognizer Swap)** | Sử dụng bộ nhận dạng VLM 0,9\te[span_149](start_span)[span_149](end_span)xt{B} của PaddleOCR-VL-1.6. | Sử dụng DeepSeek-OCR 2 (3\text{B}) làm bộ nhận dạng cục bộ. | Tách biệt lợi ích của kiến trúc điều phối khỏi năng lực suy luận nhân quả nội tại của DeepEncoder V2. |
| 8. Định tuyến tin cậy (Confidence Routing) | Chạy nhận dạng hai lần trên mọi vùng của trang tài liệu. | Chỉ kích hoạt mô hình thứ hai / sửa lỗi trên các vùng có điểm S_k thấp. | Đánh giá tỷ lệ tiết kiệm thời gian suy luận (sec/page) so với độ chính xác đạt được. |

Mọi ca lỗi phát sinh trên tập kiểm thử cần được gán nhãn vào hệ thống phân loại 12 nhóm lỗi chuẩn (MISS_REGION, WRONG_R[span_199](start_span)[span_199](end_span)EGION, WRONG_ORDER, BAD_SPLIT, BAD_MERGE, WRONG_LABEL, OCR_ERROR, TABLE_STRUCTURE, FORMULA_ERROR, GLOBAL_CONTEXT_ERROR, DUPLICATION, HALLUCINATION) để trả lời chính xác câu hỏi: *Hình học của Paddle đã sửa được nhóm lỗi nào của DeepSeek, và việc cắt nhỏ ảnh làm DeepSeek đánh mất những gì?*

# Kết Luận Và Lộ Trình Triển Khai Chiến Lược

Phân tích toàn diện trên dẫn đến một lộ trình kỹ thuật rõ ràng gồm ba cổng quyết định (decision gates) liên tiếp nhau. Ở bước khởi đầu, hệ thống cần được triển khai ngay theo kiến trúc Giai đoạn 1 (Zero-Training POC) thông qua các dịch vụ vi mô cách ly môi trường: loại bỏ hoàn toàn LayoutLMv3 và ý tưởng tự tạo bộ mã hóa thứ tự đọc rời rạc; thay vào đó sử dụng trực tiếp PaddlePaddle/PP-DocLayoutV3 kết hợp bộ dò văn bản dư (\operatorname{coverage} < \tau) và kỹ thuật che mặt nạ đa giác để tạo các vùng ảnh sạch đưa vào deepseek-ai/DeepSeek-OCR-2 chạy song song cùng một nhánh toàn trang và tầng kiểm chứng ParseFixer.

Sau khi thu thập đầy đủ số liệu từ ma trận thực nghiệm ở Giai đoạn 1, quá trình phát triển sẽ bước vào Cổng Quyết Định Khoa Học (Scientific Gate): chỉ chuyển sang Giai đoạn 2 (viết mã và huấn luyện tầng Adapter không gian tiềm ẩn) nếu kết quả thực nghiệm của Giai đoạn 1 chứng minh đồng thời hai bất đẳng thức là \text{PP-DocLayoutV3 + DeepSeek Crops (C)} > \text{DeepSeek Full-Page (B)} về độ chính xác bố cục, thứ tự đọc hoặc nhận dạng vùng dày đặc, và \text{Local + Global + Residual (E)} > \text{Local Only (C)}. Khi cả hai điều kiện này cùng thỏa mãn, bằng chứng thực nghiệm đã xác nhận rằng hình học tường minh của Paddle bổ sung thông tin thiết yếu mà luồng nhân quả ngầm định của DeepSeek còn thiếu, nhưng việc cắt ảnh rời rạc lại làm suy giảm ngữ cảnh toàn trang — đây chính là tiền đề khoa học vững chắc nhất chứng minh sự cần thiết của một kiến trúc chia sẻ đặc trưng toàn trang ở không gian tiềm ẩn. Ngược lại, nếu bản thân PaddleOCR-VL-1.6 nguyên bản (Cấu hình A) đã đạt kết quả ngang bằng hoặc vượt trội hơn tổ hợp lai trên tập dữ liệu mục tiêu với chi phí tính toán thấp hơn nhiều, hướng đi tối ưu là dừng lại ở việc tinh chỉnh hậu kỳ hoặc khai phá dữ liệu theo quy trình của PaddleOCR-VL-1.6 thay vì huấn luyện một kiến trúc mới.

Cuối cùng, khi vượt qua cổng kiểm chứng thực nghiệm để bước vào Giai đoạn 2 nhằm hiện thực hóa kiến trúc U-Net nhân quả, hệ thống sẽ đóng băng toàn bộ trọng số của cả PP-DocLayoutV3 và DeepSeek-OCR 2, lấy mẫu đặc trưng vùng (MaskPool/RoIAlign) trực tiếp

trên các tầng trung gian của bộ mã hóa thị giác DeepSeek, cấp phát đa khe truy vấn động theo độ phức tạp của từng vùng, điều kiện hóa chuỗi truy vấn luồng nhân quả Q_0 bằng cơ chế chú ý chéo có cổng khởi tạo bằng không (Q' = Q_0 + \sigma(\gamma)A) kèm nhóm truy vấn toàn cục không neo, và hoàn thiện đường truyền tắt không gian đa tầng theo đúng phương trình \hat{V} = V^{\text{final}} + \lambda G' của SARA. Lộ trình phát triển theo từng bước kiểm chứng này vừa bảo toàn trọn vẹn tính sáng tạo trong ý tưởng kết hợp ban đầu, vừa loại bỏ triệt để rủi ro lãng phí tài nguyên vào các phép ghép nối không gian tiềm ẩn bất tương thích.

## Nguồn trích dẫn

1. DeepSeek-OCR 2: The AI That Learned to Read Like a Human, https://kingy.ai/news/deepseek-ocr-2-the-ai-that-learned-to-read-like-a-human/ 2. RT-DocLayout: Real-Time End-to-End Document Layout Analysis, https://arxiv.org/html/2606.23344v1 3. PaddlePaddle/PP-DocLayoutV3 - Hugging Face, https://huggingface.co/PaddlePaddle/PP-DocLayoutV3 4. PaddleOCR-VL-1.5 Architecture - Viblo.asia, https://viblo.asia/p/paddleocr-vl-15-architecture-Nj4vgG80J6r 5. PaddleOCR-VL-1.6: Expanding the Frontier of Document Parsing, https://arxiv.org/html/2606.03264v1 6. DeepSeek OCR 2: Complete Guide to Running & Fine-tuning in 2026, https://dev.to/czmilo/deepseek-ocr-2-complete-guide-to-running-fine-tuning-in-2026-3odb 7. [2601.20552] DeepSeek-OCR 2: Visual Causal Flow - arXiv, https://arxiv.org/abs/2601.20552 8. Papers Explained 536: DeepSeek-OCR 2 | by Ritvik Rastogi - Medium, https://ritvik19.medium.com/papers-explained-536-deepseek-ocr-2-3478359cd7bc 9. LayTextLLM: A Bounding Box is Worth One Token - arXiv, https://arxiv.org/html/2407.01976v2 10. A Bounding Box is Worth One Token - Interleaving Layout and Text, https://arxiv.org/html/2407.01976v3 11. PaDoc: Layout-Grounded Parallel Decoding for Document Parsing, https://arxiv.org/html/2608.06146v1 12. Jiabo Zhan - CatalyzeX, https://www.catalyzex.com/author/Jiabo%20Zhan 13. GitHub - Longin-Yu/Padoc, https://github.com/Longin-Yu/Padoc 14. Read, Parse, Describe: Unified Document Parsing with Visual, https://www.paperpeel.com/paper/2610.20335 15. Unified Document Parsing with Visual Element Description Generation, https://paper.dou.ac/p/2610.20335v1 16. PaddleOCR/docs/index.en.md at main - GitHub, https://github.com/PaddlePaddle/PaddleOCR/blob/main/docs/index.en.md 17. PaddlePaddle/PaddleOCR-VL-1.6 - vLLM Recipes, https://recipes.vllm.ai/PaddlePaddle/PaddleOCR-VL-1.6 18. ParseFixer: An Agentic Framework for Document Parsing via ... - arXiv, https://arxiv.org/pdf/2606.11977 19. Dolphin: Document Image Parsing via Heterogeneous Anchor, https://www.alphaxiv.org/abs/2505.14059 20. MinerU2.5: A Decoupled Vision-Language Model for Efficient High, https://arxiv.org/abs/2509.22186 21. PP-DocLayoutV3 · OpenVINO IR - Model Details, https://modelscope.cn/models/FionaGu1019/PP-DocLayoutV3-ov 22. Trying PaddleOCR-VL-1.5 + PP-DocLayoutV3 as a self-hostable, https://www.reddit.com/r/computervision/comments/1sx7j0m/trying_paddleocrvl15_ppdoclayoutv3_as_a/ 23. PaddleOCR-VL-1.6 - a PaddlePaddle Collection - Hugging Face, https://huggingface.co/collections/PaddlePaddle/paddleocr-vl-16 24. PP-DocLayoutV3: layout detection for curved text - YouTube, https://www.youtube.com/shorts/a3iUAsJLIOg 25. Add support for PP-DocLayout-V3 layout detection and polygon, https://github.com/docling-project/docling/issues/3224 26. DeepSeek-OCR-2 - SGLang Documentation, https://lmsysorg.mintlify.app/cookbook/autoregressive/DeepSeek/DeepSeek-OCR-2 27. The

official repo for “Dolphin: Document Image Parsing via ... - GitHub, https://github.com/bytedance/Dolphin 28. Document Image Parsing via Heterogeneous Anchor Prompting, https://arxiv.org/html/2505.14059v1 29. DeepSeek-OCR-2 Online - Visual Causal Flow & Structured, https://deepseekocr.io/deepseek-ocr-2 30. DeepSeek-OCR 2: Model, Setup & Alternatives - The Rundown AI, https://www.therundown.ai/tools/deepseek-ocr-2